TRANSPORTE PÚBLICO QUIZ (NÍVEL AVANÇADO)

Transição da Pesquisa Operacional para MDP e Q-Learning no Controle de Frotas

Gabarito Comentado e Justificativas Matemáticas para os Corredores de João Pessoa

---

Público-Alvo: Engenheiros de Machine Learning, Pesquisadores de Transporte e Desenvolvedores de Sistemas Inteligentes.
Objetivo do Instrumento: Avaliar o domínio teórico e prático na transição de heurísticas combinatórias da Pesquisa Operacional Clássica (Branch-and-Bound, TSP, Roteamento Estático) para a modelagem dinâmica via Processos de Decisão de Markov (MDP/Dec-POMDP) e Aprendizado por Reforço (Q-Learning, DDQN) contra o agrupamento de ônibus (*bus bunching*) sob demanda estocástica.

Questão 1: Natureza Dinâmica do Bus Bunching e Falha de Rotas Estáticas

Por que os cronogramas fixos derivados de modelos clássicos de Pesquisa Operacional (como formulações lineares inteiras mistas do TSP ou VRPTW) falham inevitavelmente em prevenir o *bus bunching* nos corredores urbanos com tráfego misto?

(A) Porque os algoritmos exatos de PO são incapazes de encontrar a solução ótima global mesmo sob parâmetros determinísticos.

(B) Porque o *bus bunching* decorre de um ciclo de retroalimentação positiva instável: pequenas perturbações no tempo de percurso atrasam o veículo líder, acumulando mais passageiros nas paradas e aumentando o *dwell time*, enquanto o veículo seguidor encontra menos demanda e acelera.

(C) Porque os modelos clássicos de PO exigem espaço de estados contínuo, inviabilizando o uso de variáveis binárias para paradas de controle.

(D) Porque a Pesquisa Operacional não permite minimizar tempos médios de espera de passageiros, focando exclusivamente no custo de combustível da frota.

Resposta Correta: (B)
Justificativa Técnica: O agrupamento de ônibus é uma instabilidade sistêmica inerente ao transporte público de alta frequência. Quando um ônibus sofre um atraso inicial estocástico (devido a semáforos ou tráfego), o intervalo (*headway*) até o ônibus anterior cresce, resultando em um maior número de passageiros acumulados na plataforma. Isso prolonga o tempo de embarque/desembarque (*dwell time*), ampliando ainda mais o atraso do líder, ao passo que o ônibus seguinte atende menos passageiros e o alcança. Tabelas horárias estáticas calculadas *a priori* são de malha aberta (*open-loop*) e não possuem mecanismos dinâmicos de autocorreção em tempo real.

Questão 2: Complexidade Computacional Online (PO vs. DRL)

Em relação à viabilidade de execução em tempo real nos centros de controle operacional (CCO), qual a principal vantagem computacional de uma política de *Deep Reinforcement Learning* (DRL) treinada frente a solucionadores clássicos baseados em *Branch-and-Bound* ou Programação Dinâmica exata?

(A) O algoritmo de DRL elimina a necessidade de sensores GPS e dados de bilhetagem eletrônica a bordo.

(B) Solucionadores de PO necessitam de treinamento offline por milhões de épocas, enquanto o DRL não exige fase prévia de otimização.

(C) A inferência de uma rede neural profunda opera em complexidade $\mathcal{O}(1)$ (passagem direta/*forward pass* em milissegundos), enquanto a reotimização exata via *Branch-and-Bound* enfrenta explosão combinatória NP-difícil diante de perturbações imprevistas.

(D) O DRL garante matematicamente a convergência para o ótimo global irrestrito em qualquer topologia arbitrária de trânsito em menos de um segundo.

Resposta Correta: (C)

Justificativa Técnica: Métodos exatos de programação matemática exigem resolver instâncias combinatórias inteiras mistas a cada nova perturbação detectada, o que se torna computacionalmente proibitivo quando decisões precisam ser tomadas no intervalo de segundos em que o ônibus se aproxima da parada. No DRL, o custo computacional pesado é transferido inteiramente para a fase de treino offline (simulação em eventos discretos); em operação real, a decisão é tomada instantaneamente por uma simples avaliação tensorial na rede neural.

Questão 3: Espaço de Estados e o Problema da Não-Estacionariedade (Dec-POMDP)

No controle descentralizado de frotas onde múltiplos ônibus atuam como agentes em paradas distintas, a tomada de decisão independente pode desestabilizar o treinamento devido à não-estacionariedade do ambiente. Qual extensão do vetor de observações locais (paradigma de *High Awareness*) soluciona essa limitação de forma eficiente?

(A) Restringir a observação apenas à velocidade instantânea do veículo e ao nível de combustível no tanque.

(B) Incluir no vetor de estado local o índice normalizado da parada (k/c), o *headway* dianteiro (h_{ik}), o *headway* traseiro estimado ($h^{est}_{i+1,k}$), o *headway* observado pelo veículo líder ($h_{i-1,k}$), a carga residual a bordo ($L_{ik} - G_{ik}$) e a demanda da plataforma.

(C) Centralizar todas as decisões em uma única tabela Q tabular global com discretização de granularidade infinita.

(D) Substituir o espaço de estados por uma função determinística baseada na distância geométrica euclidiana até a praia de Tambaú.

Resposta Correta: (B)

Justificativa Técnica: Em sistemas multiagente descentralizados e assíncronos, o ambiente parece não markoviano porque as transições de estado do agente i sofrem interferência direta das ações tomadas pelos agentes vizinhos ($i-1$ e $i+1$). A literatura moderna (Rodriguez et al., 2023) demonstra que incluir o intervalo do líder anterior ($h_{i-1,k}$) e a estimativa do intervalo do seguidor ($h^{est}_{i+1,k}$) fornece consciência contextual bidirecional (*two-way looking*), estabilizando a convergência da política sem exigir comunicação interveicular de altíssima largura de banda.

Questão 4: Espaço de Ações e Restrições de Stop-Skipping Cooperativo

Ao combinar as estratégias de retenção (*holding*) e pulo de parada (*stop-skipping*) no espaço de ações de um agente de RL, qual regra de viabilidade operacional deve ser estritamente imposta para salvaguardar a acessibilidade dos usuários?

(A) O pulo de parada deve ser acionado exclusivamente quando o ônibus estiver completamente vazio.

(B) O agente pode pular paradas consecutivas arbitrariamente, desde que o veículo atinja a velocidade máxima da via.

(C) O pulo de parada (*stop-skipping*) só é autorizado se o veículo precedente $(i-1)$ não tiver pulado a mesma parada (prevenindo rejeição consecutiva de passageiros na plataforma) e se a parada não for o terminal de partida.

(D) O veículo deve ignorar tanto desembarques quanto embarques em todas as paradas intermediárias para recuperar o atraso da viagem.

Resposta Correta: (C)

Justificativa Técnica: O *stop-skipping* seletivo viável consiste em realizar apenas o desembarque de passageiros a bordo que solicitaram parada (w_{ik}^a), liberando as portas sem permitir novos embarques para acelerar a partida do veículo atrasado. Contudo, para evitar que usuários em espera sofram penalização inaceitável de serviço (serem deixados para trás por múltiplos ônibus seguidos), restringe-se a ação proibindo que dois veículos sucessivos pulem a mesma parada, garantindo que o seguidor $(i+1)$ atenda à demanda acumulada.

Questão 5: Formulação da Função de Recompensa Centrada no Passageiro

Uma função de recompensa baseada estritamente no erro quadrático do intervalo pontual ($r = -(h-H)^2$) apresenta graves deficiências quando se introduz a ação de *stop-skipping*. Como uma recompensa postergada (*delayed passenger-centric reward*) corrige esse problema?

(A) Bonificando o motorista financeiramente por cada minuto de adiantamento na chegada ao terminal central.

(B) Avaliando o impacto da ação somente após a chegada do veículo seguinte $(i+1)$ à parada seguinte $(k+1)$, contabilizando a soma dos tempos de espera de todos os passageiros atendidos por i e $i+1$, além do acréscimo de tempo a bordo imposto pela retenção.

(C) Eliminando o cálculo de tempo de espera e avaliando unicamente o consumo de energia/diesel dos motores.

(D) Assumindo que passageiros que não conseguem embarcar desaparecem da simulação sem gerar custo para o sistema.

Resposta Correta: (B)

Justificativa Técnica: Se o agente recebesse feedback imediato pontual, a ação de pular parada pareceria artificialmente ótima porque reduziria o tempo de viagem do ônibus i. Porém, os passageiros deixados para trás na plataforma amargam tempos de espera elevados que só serão resolvidos quando o ônibus sucessor $i+1$ chegar. Avaliar a recompensa na janela conjunta entre as viagens i e $i+1$ captura fielmente o custo generalizado imposto pela decisão, incentivando o agente a pular paradas apenas se o veículo de trás estiver suficientemente próximo.

Questão 6: Fator de Desconto em Ambientes Orientados a Eventos Discretos

Em um simulador onde os passos de decisão ocorrem na chegada às paradas de controle (eventos discretos assíncronos com intervalos Δt variáveis devido a congestionamentos), por que o fator de desconto clássico $\gamma \in [0, 1)$ fixo deve ser substituído por $\gamma(\Delta t) = e^{-\beta \Delta t}$?

(A) Porque γ fixo violaria a conservação da energia na simulação física veicular.

(B) Porque passos temporais físicos desiguais distorcem a ponderação temporal dos retornos futuros: um atraso severo entre paradas exige que o decaimento exponencial reflita a duração real decorrida até o próximo estado de controle.

(C) Porque o fator $e^{-\beta \Delta t}$ transforma o processo estocástico em uma equação estática de programação linear.

(D) Para impedir que a taxa de aprendizado α atinja valores negativos durante o cálculo do gradiente descendente.

Resposta Correta: (B)

Justificativa Técnica: Em formulações padrão de MDP com Δt fixo, cada transição representa uma unidade homogênea de tempo. Em transporte público sob eventos discretos (Bradtke e Duff, 1995; Rodriguez et al., 2023), o tempo entre a parada k e $k+1$ é uma variável aleatória dependente do tráfego. Se um ônibus fica preso em um engarrafamento por 20 minutos, tratar essa transição com o mesmo peso γ de uma transição fluida de 2 minutos superestimaria desproporcionalmente o impacto de eventos futuros. A taxa contínua de desconto temporal $e^{-\beta \Delta t}$ restaura a consistência matemática temporal de Bellman.

Questão 7: Viés de Superestimação no Q-Learning e o Papel do DDQN

Em ambientes estocásticos ruidosos como o trânsito urbano, o algoritmo de Q-Learning padrão com redes neurais (DQN) tende a sofrer de *Maximization Bias*. Qual mecanismo do *Double Deep Q-Network* (DDQN) elimina esse viés prejudicial?

(A) O uso de taxas de aprendizado estocásticas decrescentes até zero no primeiro episódio de treinamento.

(B) O desacoplamento entre a seleção da ação gananciosa (realizada pelos pesos da rede *online* θ) e a avaliação do valor Q dessa ação (calculada pelos parâmetros da rede de destino/*target network* θ^-).

(C) A substituição de redes neurais multicamadas por tabelas de consulta de memória estática.

(D) A eliminação completa do *Replay Buffer*, forçando o algoritmo a aprender apenas com experiências estritamente sequenciais.

Resposta Correta: (B)

Justificativa Técnica: Conforme demonstrado por Sutton e Barto (2020) e van Hasselt et al. (2015), o operador $\max_a Q(s', a)$ utiliza a mesma estimativa ruidosa para selecionar e avaliar a ação, introduzindo viés positivo sistemático. No DDQN, a meta de atualização é formulada como:

$$y_t^{DDQN} = R_{t+1} + \gamma(\Delta t) Q\left(S_{t+1}, \arg\max_{a'} Q(S_{t+1}, a'; \theta); \theta^-\right)$$

Assim, caso a rede *online* selecione erroneamente uma ação devido a ruído estatístico, a rede alvo independente tenderá a atribuir um valor menor e não correlacionado, neutralizando a superestimação.

Questão 8: O Papel Crítico do Experience Replay Buffer

Por que o armazenamento de transições $\langle s, u, r, s', \Delta t \rangle$ em uma memória de replay (*Experience Replay Buffer*) e a amostragem em mini-lotes aleatórios são essenciais no treinamento do agente de frota?

(A) Para permitir que o ônibus execute manobras de ultrapassagem física na via sem precisar de faixas dedicadas.

(B) Porque quebra a forte autocorrelação temporal entre estados consecutivos vivenciados ao longo da rota e estabiliza a convergência dos gradientes na aproximação funcional por redes neurais.

(C) Para garantir que os tempos de embarque de passageiros sejam fixos e independentes da demanda real.

(D) Para converter o aprendizado *off-policy* em um método estritamente *on-policy* equivalente ao SARSA clássico.

Resposta Correta: (B)

Justificativa Técnica: Amostras coletadas sequencialmente em uma mesma viagem de ônibus violam a premissa de dados independentes e identicamente distribuídos (i.i.d.). Se a rede for treinada diretamente na sequência temporal da rota, os pesos divergem ao superajustar aos trechos locais daquele instante específico. Amostrar mini-lotes uniformemente a partir do *Replay Buffer* randomiza as experiências de múltiplos ônibus, horários e dias simulados, estabilizando o aprendizado.

Questão 9: Métricas de Avaliação Centradas no Usuário e no Sistema

Além da redução no tempo médio de espera ($\bar{W}$), qual métrica estatística é primordial para aferir a qualidade percebida do serviço e a regularidade do intervalo sob controle por Inteligência Artificial?

(A) O volume total de passageiros pagantes em dinheiro físico na catraca do coletivo.

(B) O *Reliability Buffer Time* (RBT, diferença entre o 95º percentil e a mediana do tempo de viagem) e o Coeficiente de Variação do Headway ($c_v = \sigma_h/\mu_h$).

(C) O número de trocas de marcha efetuadas pelo motorista ao longo da Avenida Epitácio Pessoa.

(D) A temperatura média do líquido de arrefecimento do radiador durante o horário de pico.

Resposta Correta: (B)

Justificativa Técnica: Médias aritméticas podem mascarar eventos extremos de degradação do serviço. O c_v do *headway* mede diretamente a consistência do espaçamento entre ônibus (quanto menor o c_v, menor o risco de *bunching*). Já o RBT reflete a margem de tempo de segurança que o passageiro precisa planejar em seu trajeto para ter 95% de certeza de chegar no horário ao seu destino. A literatura empírica (Rodriguez et al., 2023) comprova que estratégias cooperativas de DRL reduzem não apenas as médias, mas principalmente os valores extremos (95º percentil) de espera e lotação.

Questão 10: Robustez Operacional e Não-Conformidade do Fator Humano

Em aplicações reais no sistema de transporte de João Pessoa, nem todos os motoristas cumprem integralmente as instruções de retenção geradas pelo algoritmo (problema da não-conformidade do operador). Qual comportamento é observado em políticas de DRL com alta percepção contextual (*High Awareness*) diante dessa incerteza?

(A) O sistema colapsa imediatamente, gerando atrasos infinitos em toda a malha viária municipal.

(B) A política treinada em simulação com ruído demonstra elevada robustez adaptativa, ajustando dinamicamente as decisões dos ônibus subsequentes e superando métodos convencionais rígidos como *Even Headway* (EH).

(C) O modelo é desativado e o controle reverte obrigatoriamente para despacho puramente manual por fiscais de ponto.

(D) Os ônibus passam a trafegar exclusivamente em comboios fixos de três veículos por determinação da rede neural.

Resposta Correta: (B)

Justificativa Técnica: Conforme analisado em experimentos de sensibilidade operacional (Phillips et al., 2015; Rodriguez et al., 2023), métodos heurísticos rígidos (como fórmulas fixas de *Even Headway*) assumem cumprimento determinístico e perdem drasticamente a eficácia quando um motorista ignora a instrução. Em contrapartida, agentes de DRL cooperativos avaliam em tempo real o desvio real gerado pela falha humana e compensam ativamente o espaçamento nas paradas de controle seguintes, preservando a estabilidade da frota.

Conclusão do Gabarito Comentado — Documento gerado para consolidação conceitual e alinhamento do projeto do simulador de transporte inteligente de João Pessoa / PB.