PROPOSTA TÉCNICA ACADÊMICA

Arquitetura de Aprendizado por Reforço Profundo para Controle Dinâmico de Frota e Mitigação de *Bus Bunching* em João Pessoa

Autor: Engenharia de Machine Learning & Sistemas Inteligentes de Transporte

Contexto Operacional: Projeto Otimizador de Rotas JP — Corredores Urbanos de João Pessoa (PB)

Data: Novembro de 2026

Resumo Executivo & Visão Geral do Sistema

O presente documento detalha a concepção formal e a arquitetura técnica de um agente autônomo de Inteligência Artificial voltado ao controle operacional dinâmico em tempo real da frota de transporte público de João Pessoa (PB). O objetivo central reside na mitigação ativa do fenômeno de emparelhamento de ônibus (*bus bunching*) sob condições severas de demanda estocástica e tráfego misto. Fundamentado na teoria de Processos de Decisão de Markov Parcialmente Observáveis (Dec-POMDP) e em Aprendizado por Reforço Profundo Multiagente (Double Deep Q-Network com Alta Percepção de Vizinhança), o sistema integra de forma cooperativa ações de retenção seletiva (*holding*) e pulo de paradas com embarque restrito (*stop-skipping*). Demonstra-se matematicamente e conceitualmente a superioridade desta abordagem frente aos métodos estáticos e combinatórios da Pesquisa Operacional clássica.

1 Introdução e Dinâmica do *Bus Bunching*

O fenômeno do agrupamento de veículos (*bus bunching*) configura uma instabilidade inerente e bem documentada nos sistemas de transporte público urbano (Rezazada et al., 2024; Daganzo, 2009). Em corredores de tráfego misto como as principais avenidas troncais de João Pessoa (e.g., Av. Epitácio Pessoa, Av. Dom Pedro II e corredores de ligação aos bairros de Mangabeira e Bancários), perturbações pontuais provocadas por semáforos, congestionamentos ou flutuações nas taxas de chegada de passageiros causam pequenos atrasos ao veículo que lidera uma viagem.

Ao atrasar, o intervalo de tempo até a passagem anterior (*headway*) se amplia, acumulando um volume superior de passageiros nas paradas subsequentes. Isso estende o tempo de embarque (*dwell time*), gerando um ciclo de retroalimentação positiva instável (*positive feedback loop*): o ônibus retardatário atrasa-se cumulativamente, enquanto o veículo seguinte encontra paradas progressivamente mais vazias, acelera seu percurso e acaba emparelhando fisicamente com o veículo líder (Wang, 2022). O resultado prático é a degradação do nível de serviço, elevação desproporcional do tempo médio de espera nas paradas (*Average Wait Time* - AWT) e grande variabilidade de lotação (Rezazada et al., 2024; Rodriguez et al., 2023).

Para reverter essa dinâmica, esta proposta estrutura um controlador autônomo inteligente em malha fechada que regula os intervalos operacionais através de decisões ativas em tempo real.

2 Arquitetura do Agente: Framework PEAS

A especificação do agente inteligente orienta-se pela metodologia de Engenharia de IA no framework PEAS (*Performance, Environment, Actuators, Sensors*):

Componente	Elemento Operacional	Especificação Técnica / Descrição
Performance	*Métrica Multiobjetivo Centrada no Usuário*	• Minimização do tempo médio de espera dos passageiros nas paradas ($\bar{W}$); • Redução do *Reliability Buffer Time* (RBT, diferencial entre percentil 95% e mediana do tempo de viagem); • Minimização do coeficiente de variação dos intervalos (c_v do *headway*); • Homogeneização da taxa de ocupação dos veículos ao longo do itinerário; • Penalização ponderada do tempo excessivo de retenção a bordo e de passageiros rejeitados (*denied boardings*).
Environment	*Ambiente Simulado via OpenAI Gymnasium*	• Modelagem de eventos discretos baseada no ecossistema `Gymnasium` (`step()`, `reset()`), acoplada a micro/mesosimuladores calibrados (e.g., SUMO ou simulador orientado a eventos); • Dinâmica assíncrona orientada a eventos nas chegadas às paradas de controle; • Processos de chegada estocásticos de passageiros via distribuição de Poisson não-homogênea ($\lambda_k(t)$); • Tempos de percurso nos elos com variabilidade log-normal e tempos de transação de portas ($t_b = 3{,}0\,\text{s/pax}$, $t_a = 1{,}8\,\text{s/pax}$).
Actuators	*Mecanismos de Controle Operacional de Bordo*	• **Retenção Ativa (*Holding*):** Instrução digital no console do condutor postergando a partida por um período adicional T_{ik}^{hold}; • **Pulo de Parada Seletivo (*Stop-Skipping*):** Autorização para liberação imediata do ônibus após o desembarque (w_{ik}^{a}), suprimindo novos embarques para recuperação célere de atraso crítico.
Sensors	*Percepção Telemática em Tempo Real (ITS)*	• Sistema de Localização Automática de Veículos (AVL / GPS embarcado); • Bilhetagem Eletrônica (AFC) e Contadores Automáticos de Passageiros (APC); • Sensores de telemetria de portas e odometria veicular.

Table 1: Especificação PEAS do Agente Inteligente de Controle de Frota.

3 Motor Matemático: Formulação Rigorosa do Dec-POMDP

Como as decisões ocorrem de forma assíncrona quando cada ônibus alcança uma parada de controle designada $k \in \{1, \ldots, c\}$, o sistema é formalizado rigorosamente como um Processo de Decisão de Markov Parcialmente Observável Descentralizado (Dec-POMDP) definido pela tupla:

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle \tag{1}$$

3.1 Espaço de Estados ($\mathcal{S}$) e Observações Locais de Alta Consciência

A literatura clássica de controle multiagente descentralizado frequentemente sofre com a *não-estacionariedade*: do ponto de vista de um ônibus individual, as transições parecem não-markovianas porque outros ônibus interferem continuamente no estado da rede (Rodriguez et al., 2023; Idris & Cabri, 2026). Para contornar essa limitação sem incorrer em sobrecarga computacional excessiva, adota-se o vetor de observação local de **alta percepção de vizinhança** (*High-Awareness State Space*):

$$s_{ik} = \left[\frac{k}{c},\ h_{ik},\ h_{i+1,k}^{est},\ h_{i-1,k},\ (L_{ik} - G_{ik}),\ \hat{B}_k \right]^{\top} \in \mathbb{R}^6 \tag{2}$$

onde:

1. $\frac{k}{c} \in (0, 1]$: Índice normalizado da parada de controle atual em relação ao total de pontos de controle da linha, fornecendo perspectiva espacial contínua.
2. $h_{ik} = A_{ik} - A_{i-1,k}$: Intervalo dianteiro real (*forward headway*) entre a viagem atual i e a precedente $i-1$ na parada k.
3. $h^{est}_{i+1,k} = A^{est}_{i+1,k} - A_{ik}$: Intervalo traseiro estimado (*estimated backward headway*) até a chegada prevista do veículo sucessor $i+1$.
4. $h_{i-1,k}$: Intervalo dianteiro observado pelo veículo da frente ao passar pela mesma parada, introduzindo dependência temporal explícita para amortecer a não-estacionariedade.
5. $L_{ik} - G_{ik}$: Carga líquida de passageiros a bordo que permanecem após o desembarque de G_{ik} usuários (passageiros que sofrerão atraso direto caso seja aplicado *holding*).
6. $\hat{B}_k$: Demanda estimada de passageiros na plataforma aguardando embarque, inferida via taxa histórica λ_k e pelo tempo decorrido desde a última partida: $\hat{B}_k \approx \lambda_k \cdot h_{ik}$.

3.2 Espaço de Ações ($\mathcal{A}$)

Ao chegar à parada k, o agente seleciona uma ação discreta de controle $u_{ik} \in \mathcal{A}$:

$$\mathcal{A} = \{\text{Sem Controle}\} \cup \{\text{Holding}(\omega) \mid \omega \in \Omega\} \cup \{\text{Stop-Skipping}\} \tag{3}$$

sendo $\Omega = \{0{,}1;\ 0{,}2;\ 0{,}3;\ 0{,}4\}$ o conjunto de frações do intervalo programado H_i.

- **Estratégia de Retenção (*Holding*):** O instante de partida D_{ik} é postergado pela duração de retenção $T^{hold}_{ik} = \omega H_i$, sendo o tempo efetivo de saída governado por:

$$D_{ik} = A_{ik} + \max\left\{T^{hold}_{ik},\ w_{ik}\right\} \tag{4}$$

  onde w_{ik} é o tempo natural de permanência devido ao embarque e desembarque.

- **Estratégia de Pulo de Parada (*Stop-Skipping* Seletivo):** O ônibus atende exclusivamente aos desembarques solicitados (w^a_{ik}), fechando as portas imediatamente sem admitir novos passageiros (evitando passageiros deixados para trás em duas paradas consecutivas mediante verificação de viabilidade):

$$D_{ik} = A_{ik} + w^a_{ik} \tag{5}$$

3.3 Probabilidades de Transição Estocásticas ($\mathcal{P}$)

A probabilidade de transição $\mathcal{P}(s_{i,k+1} \mid s_{ik}, u_{ik})$ reflete a física do sistema de tráfego urbano e as chegadas estocásticas de passageiros:

$$\mathcal{P}(s_{i,k+1} \mid s_{ik}, u_{ik}) = \Pr(S_{t+1} = s_{i,k+1} \mid S_t = s_{ik}, A_t = u_{ik}) \tag{6}$$

Como demonstrado por Sutton & Barto (2018), em ambientes de alta complexidade estocástica onde a matriz analítica $\mathcal{P}$ é intratável, algoritmos de Aprendizado por Reforço *model-free* operam realizando amostragem direta de trajetórias observadas sem necessidade de estimar $\mathcal{P}$ explicitamente.

3.4 Função de Recompensa ($\mathcal{R}$): Formulação Centrada no Passageiro

A formulação padrão de recompensas baseada unicamente no desvio de intervalo pontual falha ao incorporar ações combinadas de pulo de parada, pois passageiros rejeitados no *stop-skipping* só são compensados na chegada do ônibus seguinte. Assim, adota-se a formulação postergada e cooperativa proposta por Rodriguez et al. (2023), calculada quando o ônibus seguinte $i+1$ alcança o ponto de controle subsequente $k+1$:

$$R_{ik} = W_{wait} \cdot r^{wait}_{i,k+1} + r^{ride}_{i,k+1} \tag{7}$$

onde:

$$r^{wait}_{i,k+1} = -\sum_{y=i}^{i+1} \sum_{z=\rho(k)}^{\rho(k+1)-1} \sum_{p \in \mathcal{P}_{yz}} T^{wait}_p \tag{8}$$

$$r^{ride}_{i,k+1} = -\sum_{z=\rho(k)}^{\rho(k+1)-1} \sum_{p \in \mathcal{P}_{iz}} T^{ride}_p \tag{9}$$

O primeiro termo penaliza a soma dos tempos de espera de todos os usuários que embarcam em i e $i+1$ nas paradas intermediárias $z \in [\rho(k), \rho(k+1)-1]$. Essa inclusão mútua obriga o agente que comanda i a cooperar e só aplicar *stop-skipping* quando o sucessor $i+1$ estiver perto o bastante para recolher os passageiros remanescentes sem atrasos críticos. O hiperparâmetro W_{wait} (calibrado empiricamente em $W_{wait} \approx 9$) reflete o custo percebido superior do tempo de espera frente ao tempo a bordo.

3.5 Fator de Desconto (γ) em Ambientes Orientados a Eventos

No controle síncrono padrão com passo fixo, o retorno descontado é $G_t = \sum_{j=0}^{\infty} \gamma^j R_{t+j+1}$. No entanto, no controle de ônibus as transições são assíncronas e ocorrem em intervalos temporais variáveis $\Delta t = t_{k+1} - t_k$. O emprego de um γ constante geraria distorções temporais. Emprega-se a formulação contínua para MDPs orientados a eventos (Bradtke & Duff, 1995; Rodriguez et al., 2023):

$$\gamma(\Delta t) = e^{-\beta \Delta t} \tag{10}$$

onde $\beta > 0$ representa a taxa contínua de desconto temporal.

- **Efeito Prático:** Se o veículo enfrenta um trecho com congestionamento atípico (Δt extenso), $e^{-\beta \Delta t}$ decai acentuadamente, concentrando a otimização no restabelecimento do equilíbrio local em vez de propagar incertezas desproporcionais sobre estados futuros distantes.

4 Algoritmo de Aprendizado: Double Deep Q-Network (DDQN)

Para contornar a superestimação de valores de ação característica do Q-Learning padrão em ambientes ruidosos (Sutton & Barto, 2018), o algoritmo implementa Double Deep Q-Networks (DDQN), desacoplando a seleção da ação da sua avaliação:

$$y^{DDQN}_t = R_{t+1} + e^{-\beta \Delta t} Q\left(S_{t+1},\, \arg\max_{a'} Q(S_{t+1}, a'; \theta);\, \theta^-\right) \tag{11}$$

A rede é otimizada minimizando a função de perda sobre o *Experience Replay Buffer* $\mathcal{D}$:

$$\mathcal{L}(\theta) = \mathbb{E}_{(s,u,r,s',\Delta t)\sim\mathcal{D}}\left[\left(y^{DDQN}_t - Q(s,u;\theta)\right)^2\right] \tag{12}$$

onde θ representa os parâmetros da rede neural profunda ativa e θ^- representa os pesos da rede de destino (*target network*), atualizados a cada τ passos de treinamento.

5 Justificativa Técnica: RL Dinâmico vs. Pesquisa Operacional Clássica

As abordagens tradicionais de Pesquisa Operacional (PO) baseiam-se em formulações analíticas determinísticas ou estocásticas por cenários: Programação Linear Inteira Mista (MILP), algoritmos de *Branch-and-Bound*, e formulações combinatórias derivadas do Problema do Caixeiro Viajante (TSP) e Roteamento de Veículos com Janelas de Tempo (VRPTW). A Tabela 2 sintetiza o confronto metodológico:

Dimensão Analítica	**Pesquisa Operacional Clássica (Branch-and-Bound, MILP, TSP)**	**Deep Reinforcement Learning (DDQN Descentralizado / IPPO-DH)**
Tratamento da Estocasticidade	Modelagem baseada em valores médios ou cenários discretizados; altamente vulnerável a dispersões de tráfego e picos inesperados de demanda.	Intrínseca e adaptativa; a política é treinada diretamente sobre distribuições empíricas estocásticas, generalizando para estados operacionais imprevistos.
Complexidade Computacional Online	Explosão combinatória NP-difícil. A reotimização exata via *Branch-and-Bound* para redes completas exige minutos ou horas, inviabilizando decisões em tempo real.	Complexidade de inferência em tempo de execução $\mathcal{O}(1)$. O modelo realiza um único passe *forward* na rede neural treinada, respondendo em milissegundos.
Regime de Operação	Controle estático em malha aberta (*open-loop*). Produz tabelas horárias rígidas incapazes de reagir após o início do acúmulo de atraso.	Controle dinâmico em malha fechada (*closed-loop*). O agente monitora desvios continuamente e atua com micro-correções preventivas.
Modelagem do Feedback de Atraso	Tempos de parada tratados comumente como constantes ou simplificados, ignorando a dinâmica cumulativa de embarque.	Modela diretamente a retroalimentação instável do *dwell time* e a cooperação mútua entre veículos adjacentes na linha.

Table 2: Comparativo Metodológico: Pesquisa Operacional Clássica vs. Deep RL Dinâmico.

5.1 Conexão Teórica e Complementaridade Metodológica

O paradigma de Aprendizado por Reforço Profundo não invalida os fundamentos rigorosos da Pesquisa Operacional; pelo contrário, ele representa a extensão direta da Programação Dinâmica de Bellman para regimes contínuos e estocásticos em que a enumeração exata do espaço de estados torna-se intratável pela maldição da dimensionalidade (Sutton & Barto, 2018).

Enquanto solucionadores exatos de PO são indispensáveis na fase estratégica (dimensionamento inicial de frota e definição de itinerários mestre), eles colapsam sob o dinamismo operacional de João Pessoa, onde chuvas repentinas, tráfego misto em cruzamentos semafóricos e flutuações de demanda desestabilizam qualquer tabela estática pré-calculada. O agente de DRL dinâmico atua como um modulador em tempo real, corrigindo perturbações pontuais através de micro-retenções ponderadas e pulos cirúrgicos de parada, eliminando o *bus bunching* antes que ele se propague pela malha urbana.

6 Conclusão

A arquitetura técnica delineada combina o rigor conceitual da teoria dos Processos de Decisão de Markov com a capacidade de generalização das redes neurais profundas (DDQN). Ao expandir o espaço de observação para incluir métricas de alta percepção de vizinhança e formular uma

função de recompensa orientada aos custos generalizados do passageiro, o sistema resolve a não-estacionariedade do controle descentralizado e proporciona um controle robusto e adaptativo para a cidade de João Pessoa.

Referências Bibliográficas

- **Bradtke, S., & Duff, M. O.** (1995). Reinforcement learning methods for continuous-time Markov decision problems. *Advances in Neural Information Processing Systems*, MIT Press, pp. 393–400.
- **Daganzo, C. F.** (2009). A headway-based approach to eliminate bus bunching: Systematic analysis and comparisons. *Transportation Research Part B: Methodological*, 43(10), 913–921.
- **Idris, H. A., & Cabri, G.** (2026). Adaptive Public Transit Scheduling via Reinforcement Learning: A Survey of Techniques, Challenges, and Opportunities. *Preprints.org*, doi:10.20944/preprints202609.0014.v1.
- **Laskaris, G., Cats, O., Jenelius, E., Rinaldi, M., & Viti, F.** (2021). A holding control strategy for diverging bus lines. *Transportation Research Part C: Emerging Technologies*, 125, 103087.
- **Rezazada, M., Nassir, N., Tanin, E., & Ceder, A.** (2024). Bus bunching: a comprehensive review from demand, supply, and decision-making perspectives. *Transport Reviews*, 44(4), 767–796.
- **Rodriguez, J., Koutsopoulos, H. N., Wang, S., & Zhao, J.** (2023). Cooperative bus holding and stop-skipping: A deep reinforcement learning framework. *Transportation Research Part C: Emerging Technologies*, 155, 104308.
- **Sutton, R. S., & Barto, A. G.** (2018). *Reinforcement Learning: An Introduction*. 2nd edition, MIT Press, Cambridge, MA.
- **Wang, J., & Sun, L.** (2020). Dynamic holding control to avoid bus bunching: A multi-agent deep reinforcement learning framework. *Transportation Research Part C: Emerging Technologies*, 116, 102661.
- **Wang, X.** (2022). Integrating Conventional Headway Control with Reinforcement Learning to Avoid Bus Bunching. *arXiv preprint arXiv:2210.00201*.